

机器学习入门知识点

刘超

计算机科学与技术学院

2026 年 8 月 3 日

摘要

本报告从理论与数学层面系统梳理了机器学习入门所需的核心知识。内容分为两大部分：第一部分阐述基本原理，涵盖机器学习、深度学习与强化学习的基本范式，训练过程、前向传播与反向传播的数学形式、收敛性分析以及常用的性能评价指标；第二部分从线性回归出发，逐个解析线性回归、逻辑回归、决策树、支持向量机、 K 近邻、 K 均值聚类以及前馈神经网络等基本模型，给出必要的数学推导与直观解释。

关键词：机器学习，深度学习

目录

第一部分 机器学习基本原理	4
1 机器学习的基本范式与数学框架	4
1.1 经验风险最小化	4
1.2 正则化	4
1.3 梯度下降	4
2 深度学习与前向传播	4
2.1 多层感知机	4
2.2 前向传播	5
2.3 反向传播与自动微分	5
3 强化学习初步	5
4 训练流程与收敛性	5
4.1 训练循环	5
4.2 收敛的定义	5
5 性能衡量指标	6
5.1 回归指标	6
5.2 分类指标	6
第二部分 基本模型逐个解析	6
6 监督学习	6
6.1 线性回归	6
6.1.1 最小二乘法	7
6.2 逻辑回归	7
6.3 决策树	8
6.4 朴素贝叶斯	9
7 高级监督学习	10
7.1 支持向量机	10
7.2 随机森林	10
7.3 梯度提升	11
8 无监督学习	12
8.1 K 均值聚类 (K -means)	12

8.2	层级聚类	12
8.3	PCA	13
8.4	t-SNE	13
9	神经网络	14
9.1	MLP	14
9.2	CNN	15
9.3	RNN	15
10	Transformer	16
10.1	自注意力机制	16
10.2	多头注意力机制	17
10.3	BERT and GPT Models	17
10.4	Vision Transformer(ViT)	17
11	生成模型	18
11.1	GAN	18
11.2	VAE	19
11.3	Diffusion	19
	总结	20

第一部分 机器学习基本原理

1 机器学习的基本范式与数学框架

1.1 经验风险最小化

机器学习的目标是寻找一个映射 $f: \mathcal{X} \rightarrow \mathcal{Y}$, 使其在未知分布 $p_{\text{data}}(\mathbf{x}, y)$ 上的期望风险最小。由于真实分布不可知, 实际中最小化经验风险:

$$\hat{R}(f) = \frac{1}{N} \sum_{i=1}^N \ell(f(\mathbf{x}^{(i)}), y^{(i)}), \quad (1)$$

其中 ℓ 为损失函数。常见任务包括回归(均方误差)、二分类(交叉熵)和多分类(Softmax 交叉熵)。

1.2 正则化

为防止过拟合, 在经验风险上添加正则项, 例如 L_2 正则化:

$$J(\boldsymbol{\theta}) = \frac{1}{N} \sum_{i=1}^N \ell(f(\mathbf{x}^{(i)}; \boldsymbol{\theta}), y^{(i)}) + \lambda \|\boldsymbol{\theta}\|_2^2. \quad (2)$$

1.3 梯度下降

最小化目标 $J(\boldsymbol{\theta})$ 最常用的方法为梯度下降及其变种:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \nabla_{\boldsymbol{\theta}} J(\boldsymbol{\theta}_t), \quad (3)$$

其中 η 为学习率。实际应用中, 小批量随机梯度下降 (Mini-batch SGD) 在效率与稳定性之间取得平衡。

2 深度学习与前向传播

2.1 多层感知机

深度前馈网络将多个非线性变换堆叠, 一个 L 层网络可表示为复合函数:

$$f(\mathbf{x}) = f^{(L)} \circ f^{(L-1)} \circ \dots \circ f^{(1)}(\mathbf{x}), \quad (4)$$

其中第 l 层的计算为

$$\mathbf{h}^{(l)} = \sigma^{(l)}(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (5)$$

$\mathbf{h}^{(0)} = \mathbf{x}$, $\sigma^{(l)}$ 为非线性激活函数 (ReLU、Sigmoid 等)。

2.2 前向传播

前向传播指输入 $\mathbf{x}$ 按层递推计算，逐层得到激活值，最终输出预测值 $\hat{y} = \mathbf{h}^{(L)}$ 。该过程仅依赖当前参数，不涉及参数更新。前向传播产生的中间值会被缓存在计算图中，供后续反向传播使用。

2.3 反向传播与自动微分

损失 $\mathcal{L}$ 关于各层参数的梯度通过链式法则高效计算。对第 l 层权重：

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}^{(l)}} \odot \sigma^{(l)'} \cdot (\mathbf{h}^{(l-1)})^\top. \quad (6)$$

现代框架基于计算图自动完成该过程（自动微分）。

3 强化学习初步

强化学习研究智能体在环境中通过试错学习最优策略的过程，形式化为马尔可夫决策过程 $(\mathcal{S}, \mathcal{A}, p, r, \gamma)$ 。目标是最大化累积折扣奖励 $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$ 。核心概念包括状态值函数 $V^\pi(s)$ 、动作值函数 $Q^\pi(s, a)$ ，它们满足贝尔曼方程。深度强化学习利用神经网络逼近值函数或直接参数化策略（如 DQN、PPO），使算法能够处理高维状态空间。

4 训练流程与收敛性

4.1 训练循环

模型训练通常包含以下迭代步骤：

1. 前向传播，计算损失；
2. 反向传播，计算梯度；
3. 优化器更新参数（SGD、Adam 等）；
4. 在验证集上监控指标。

4.2 收敛的定义

从优化角度看，若 $\epsilon > 0$ ，存在 T 使得对所有 $t > T$ 有 $\|\nabla J(\boldsymbol{\theta}_t)\| \leq \epsilon$ ，则称算法收敛至一个平稳点。实践中，常用验证损失不再下降作为“早停”准则。深度模型的损失曲面高度非凸，SGD 常收敛到泛化性能良好的局部极小区域。

5 性能衡量指标

5.1 回归指标

均方误差 $MSE = \frac{1}{n} \sum (\hat{y}_i - y_i)^2$ ；平均绝对误差 $MAE = \frac{1}{n} \sum |\hat{y}_i - y_i|$ ；决定系数 $R^2 = 1 - \frac{\sum (\hat{y}_i - y_i)^2}{\sum (y_i - \bar{y})^2}$ 。

5.2 分类指标

基于混淆矩阵定义精确率、召回率与 F_1 分数：

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = 2 \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (7)$$

AUC-ROC 评估不同阈值下模型的整体区分能力。多分类常采用宏平均或微平均。

第二部分 基本模型逐个解析

从本章开始，我们逐一剖析机器学习中最为经典的几个模型，给出其数学形式、学习准则与关键特性。

6 监督学习

监督学习算法是一类从带有标签的训练数据中学习输入到输出映射关系，并通过最小化预测值与真实值之间的误差来优化模型，从而对未知数据进行预测的机器学习方法。

6.1 线性回归

线性回归是机器学习中最基础、应用最广的预测连续值算法。其核心假设为：目标变量 y 与特征变量 x 之间存在线性关系

$$\hat{y} = w \cdot x + b, \quad (8)$$

其中 w 为权重（斜率）， b 为偏置（截距）， $\hat{y}$ 是预测值。模型的目标是寻找最优的 w 与 b ，使预测值与真实值之间的误差最小。通常采用均方误差（Mean Squared Error, MSE）作为损失函数：

$$\text{MSE}_{\text{section}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (9)$$

其中 y_i 为真实值， $\hat{y}_i = wx_i + b$ 为预测值， n 为样本数量。通过调整参数 w 和 b 使 MSE 最小化的过程，即线性回归的训练过程。求解方法可通过解析解（正规方程）或梯度下

降等优化算法实现。

6.1.1 最小二乘法

线性回归通常采用均方误差损失：

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - wx_i - b)^2. \quad (10)$$

令 RSS 对 w 和 b 的偏导数为零，可推出正规方程：

$$\begin{cases} w \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i = \sum_{i=1}^n x_i y_i \\ w \sum_{i=1}^n x_i + bn = \sum_{i=1}^n y_i \end{cases}$$

将上述方程组写成矩阵形式，有

$$\begin{bmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & n \end{bmatrix} \begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n y_i \end{bmatrix}. \quad (11)$$

当系数矩阵可逆时，最小二乘解的显式表达式为

$$\begin{bmatrix} w \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & n \end{bmatrix}^{-1} \begin{bmatrix} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n y_i \end{bmatrix}. \quad (12)$$

6.2 逻辑回归

逻辑回归是一种经典的二分类算法，通过 Sigmoid 函数将线性模型的输出映射为概率。它广泛应用于垃圾邮件检测、疾病预测、客户流失分析等场景。

模型：

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = wx + b$$

其中 $\hat{y}$ 表示样本属于正类的概率。

损失函数：

采用对数损失（Log Loss，即二分类交叉熵）：

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

梯度计算：

$$\frac{\partial J}{\partial w} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i) x_i, \quad \frac{\partial J}{\partial b} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)$$

6.3 决策树

决策树是一种通过树状结构进行决策的机器学习算法，可用于分类和回归。它以节点（根、内部、叶）、分支、分裂和纯度等概念为基础，直观地表示特征测试与预测结果之间的关系。

工作原理

1. **选择最佳特征**：根据纯度提升标准（如信息增益、基尼指数或均方误差）确定当前最优划分特征。
2. **分割数据集**：按选定特征将数据集划分为多个子集。
3. **递归建树**：对每个子集重复上述过程，直到满足停止条件（如节点纯度足够高、达到最大深度等）。
4. **生成叶节点**：在终止处赋予类别（分类）或数值（回归）。

常用构建标准及公式

- **信息增益（Information Gain）（分类）**：基于熵的减少量选择特征。

- 熵的定义： $H(D) = - \sum_k p_k \log_2(p_k)$ ，其中 p_k 为第 k 类的样本比例，熵值越大，不确定性越高。

- 信息增益公式： $IG(D, A) = H(D) - \sum_v \frac{|D_v|}{|D|} H(D_v)$ ，其中 A 为所选特征， D_v 为按 A 的取值划分出的子集。信息增益越大，划分提升的纯度越高。

- **基尼指数（Gini Index）（分类）**：衡量节点的不纯度。

- 基尼值公式： $Gini(D) = 1 - \sum_k p_k^2$ ，其中 p_k 为第 k 类样本的比例。基尼指数越小，表示数据越纯。

- **均方误差（MSE）（回归）**： $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$ ，选择使划分后各节点 MSE 加权和最小的特征进行分裂。

6.4 朴素贝叶斯

朴素贝叶斯是一类基于贝叶斯定理与特征条件独立假设的概率分类算法，简单高效，常用于文本分类、垃圾邮件过滤等任务。其核心思想是计算样本属于各类别的后验概率，选择概率最大的类别作为预测结果。

基本原理

- 贝叶斯公式：

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

其中 A 为类别标签， B 为特征向量， $P(A | B)$ 是后验概率， $P(B | A)$ 是似然， $P(A)$ 是先验概率， $P(B)$ 为证据因子（计算时可忽略，因为比较时与类别无关）。

- 条件独立假设：在给定类别 A 下，假设各特征相互独立，即

$$P(B | A) = \prod_{i=1}^n P(B_i | A)$$

该假设极大地简化了联合概率的计算。

- 分类决策规则：对于样本 B ，预测类别为

$$\hat{A} = \arg \max_A P(A) \prod_{i=1}^n P(B_i | A)$$

为避免下溢，通常取对数：

$$\hat{A} = \arg \max_A [\log P(A) + \sum_{i=1}^n \log P(B_i | A)]$$

常见类型

根据数据特点，主要有高斯朴素贝叶斯（连续特征）、多项式朴素贝叶斯（计数特征）、伯努利朴素贝叶斯（二值特征）。

典型流程

1. 准备数据：收集特征和类别标签，对文本等数据进行必要的向量化预处理。
2. 计算先验概率：统计训练集中各类别的频率得到 $P(A)$ 。
3. 计算条件概率：估计每个特征 B_i 在各类别下的条件概率 $P(B_i | A)$ 。
4. 预测新样本：利用决策规则计算各类别的后验概率，取最大值对应的类别。
5. 模型评估：使用准确率、混淆矩阵等指标评价性能，必要时绘制 ROC 曲线等。

7 高级监督学习

高级监督学习是传统监督学习的进阶范式，借助深度神经网络、梯度提升树等复杂模型，自动从大规模高维数据中学习深层抽象特征，结合迁移学习、注意力机制与正则化等技术，捕捉复杂非线性关系，从而在图像识别等任务中取得更优预测性能。

7.1 支持向量机

SVM 是一种监督学习算法，用于分类和回归，核心是寻找最优超平面并以最大间隔区分不同类别。

核心概念

- **超平面**：决策边界，二维为直线，三维为平面，高维为超平面，方程 $\mathbf{w} \cdot \mathbf{x} + b = 0$ 。
- **支持向量**：距超平面最近的样本点，唯一决定最优超平面。
- **最大间隔**：优化目标为最大化支持向量到超平面的距离 $\frac{2}{\|\mathbf{w}\|}$ ，从而提升泛化能力。
- **核技巧**：对非线性可分数据，通过核函数映射到高维空间，使其线性可分，避免显式计算。常用核函数：

- 线性核： $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i \cdot \mathbf{x}_j$
- 多项式核： $K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + c)^d$
- RBF 核： $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$

分类流程

1. 根据数据特性选择核函数（线性或非线性）。
2. 求解凸优化问题，寻找最大化间隔的超平面。
3. 确定支持向量。
4. 使用决策函数 $f(\mathbf{x}) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$ 进行预测。

7.2 随机森林

随机森林是一种集成学习算法，通过构建多棵决策树并聚合其结果，提升预测性能与稳定性。分类任务采用多数投票，回归任务使用平均值。

核心思想：Bagging 与随机性

- **Bagging (自助聚合):**
 - **Bootstrap (自助采样):** 从原始数据有放回地随机抽取多个子训练集，样本可重复出现或被遗漏。
 - **Aggregating (聚合):** 用每个子训练集独立训练一棵决策树，最终投票或取平均得到结果。
- **特征随机性:** 每棵树在节点分裂时，只从全部特征中随机选取一个子集，并从中选择最优分裂特征，进一步增强树间多样性。

随机森林通过数据与特征的双重随机性，构建多样化的“专家委员会”，即使部分树出错，其他树的正确投票也能纠错，从而获得比单棵决策树更强的泛化能力和鲁棒性。

7.3 梯度提升

GBR 是一种集成学习技术，通过逐步组合多个弱学习器（通常为决策树），迭代减少残差，构建强预测模型。可适用于各类可微损失函数。

工作原理

1. **初始化:** 用一个简单模型（如单个决策树）作为初始预测。
2. **计算残差:** 对每个样本，计算当前模型预测值与真实值之差。
3. **拟合残差:** 训练一个新的弱学习器去拟合这些残差，通常以最小化损失函数（如均方误差）为目标。
4. **更新模型:** 将新弱学习器的预测结果叠加到当前模型上。
5. **重复迭代:** 持续执行步骤 2-4，直至达到最大迭代次数或模型性能不再提升。

优缺点

- **优点:**
 - 预测性能高，善于处理复杂非线性关系。
 - 对噪声和异常值鲁棒性较强。
 - 灵活处理数值型和分类型特征。
- **缺点:**
 - 训练时间长，尤其在大规模数据集上。
 - 容易过拟合，尤其在样本少或弱学习器复杂时。
 - 超参数多，调优难度大。

8 无监督学习

无监督学习算法的任务是自行从数据中找出模式、结构或关系。聚类就是其中最核心的技术之一。

8.1 K 均值聚类 (K -means)

K 均值是一种无监督聚类算法，目标是将数据集划分为 K 个簇，使簇内平方和最小：

$$J = \sum_{k=1}^K \sum_{\mathbf{x} \in C_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2, \quad (13)$$

其中 $\boldsymbol{\mu}_k$ 是第 k 个簇的中心。

算法步骤

1. **确定 K 值：**预先指定要将数据分成的簇数 K 。
2. **初始化质心：**在数据空间中随机选取 K 个点作为初始质心 $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_K$ 。
3. **分配样本：**对每个样本 $\mathbf{x}_i$ ，计算其与各质心的距离（通常为欧氏距离），将其归入距离最近的质心所在簇：

$$c_i = \arg \min_k \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2$$

4. **更新质心：**对每个簇，以该簇内所有样本的均值作为新质心：

$$\boldsymbol{\mu}_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \mathbf{x}_i$$

5. **迭代收敛：**重复步骤 3 和 4，直至质心位置不再显著变化（或达到最大迭代次数），算法收敛。

8.2 层级聚类

层次聚类是一种自底向上的凝聚式聚类方法，通过反复合并距离最近的样本或类，逐步构建嵌套的簇结构，最终形成聚类谱系图（树状图）。

基本步骤：

1. **计算距离：**计算所有样本点两两之间的距离，常用欧氏距离、曼哈顿距离、切比雪夫距离等。
2. **合并最近者：**将距离最小的两个样本（或类）合并成一个新类。

3. **更新距离**: 重新计算新类与其他现有类之间的距离（可采用单链接、全链接、平均链接等策略）。
4. **迭代合并**: 重复步骤 2 和 3，直到所有样本最终合并为一个大类，并生成聚类谱系图。

8.3 PCA

PCA 是一种线性降维技术，通过正交变换将高维数据投影到低维空间，新变量（主成分）按方差大小排序，尽可能保留原始数据的变异性。

工作原理

1. **标准化**: 对各特征进行标准化，消除量纲影响。
2. **协方差矩阵**: 计算标准化数据的协方差矩阵，捕获特征间线性关系。
3. **特征值分解**: 对协方差矩阵进行特征值分解，获得特征值（方差大小）和对应特征向量（主成分方向）。
4. **选择主成分**: 按特征值从大到小选取前 k 个主成分，保留大部分方差。
5. **数据投影**: 将原始数据乘以所选特征向量矩阵，得到降维后的新特征表示。

常见应用:

- **可视化**: 将高维数据降至 2 维或 3 维，观察数据分布与模式。
- **降噪**: 舍弃低方差成分，滤除噪声，提升模型稳定性。
- **特征提取与选择**: 减少特征数量，降低模型复杂度，缓解过拟合。

8.4 t-SNE

t-SNE 是一种非线性降维方法，专注于在高维数据中保留点与点之间的局部结构。适用于可视化高维复杂数据，如图像、文本或嵌入向量等。

核心思想

- **相似性建模**: 在高维空间用高斯分布（或 t 分布）度量点间相似性；在低维空间用 t 分布建模相似性，增强远离点间的斥力。
- **目标函数**: 最小化高维与低维相似性分布之间的 Kullback-Leibler 散度，使低维嵌入尽可能保留高维的近邻关系。
- **局部结构**: 着力于保持近邻点的相对位置，放松对全局结构的精确还原，适合局部特征探索。

9 神经网络

神经网络是一种受生物神经系统启发的计算模型，由大量相互连接的神经元（节点）分层组织而成。其核心思想是通过学习数据的模式，自动调整神经元之间的连接权重，从而实现对复杂函数的逼近。

9.1 MLP

MLP 是最基础的深度学习模型，也是全连接神经网络 (FNN) 的典型代表，由多层感知机神经元堆叠而成，核心作用是拟合复杂的非线性映射关系，可完成分类、回归、特征学习等任务。

神经网络核心工作原理

神经网络的学习依赖**前向传播**（预测）与**反向传播**（训练）两大阶段交替进行。

1. 非线性激活函数

激活函数赋予网络非线性拟合能力；若缺少它，任意深度的多层感知机（MLP）等价于单层线性模型。常用激活函数（按优先顺序）：

- **ReLU**（最常用）： $f(x) = \max(0, x)$ ，计算快、缓解梯度消失，但存在“死亡神经元”问题。
- **Sigmoid**： $\sigma(x) = \frac{1}{1+e^{-x}}$ ，输出 $(0, 1)$ ，适合二分类输出层，但易导致梯度消失且输出非零均值。
- **Tanh**： $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ ，输出 $(-1, 1)$ ，零均值，仍存在梯度消失。
- **Softmax**（多分类输出层专用）：将向量映射为概率分布， $\hat{y}_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$ 。

2. 前向传播

从输入层开始，逐层计算直至输出预测值。对第 l 层：

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}, \quad \mathbf{a}^{(l)} = f(\mathbf{z}^{(l)})$$

其中 $\mathbf{W}^{(l)}$ 为权重矩阵， $\mathbf{b}^{(l)}$ 为偏置向量， f 为激活函数， $\mathbf{a}^{(l)}$ 为该层输出。

3. 反向传播

从输出层开始，利用链式求导法则逐层计算损失函数对权重和偏置的梯度，并通过优化器更新参数，以最小化损失（分类常用交叉熵，回归常用均方误差）。这一过程是训练的核心，常用优化器包括 SGD、Adam（MLP 最常用）等。

9.2 CNN

CNN 是一种深度学习模型，广泛应用于计算机视觉领域。其灵感来源于生物视觉系统，能够通过模拟人类视觉处理方式，提取图像的局部特征并实现高效的图像识别、目标检测等任务。

核心思想

CNN 通过**卷积操作**提取图像局部特征：使用一个小尺寸的卷积核在图像上滑动，对覆盖区域的像素进行逐元素相乘并求和。这种机制能够有效捕捉边缘、纹理等空间特征，并天然具备**平移不变性**。

基本结构

CNN 通常由以下几部分顺序堆叠构成：

1. **输入层**：接收原始图像（RGB 或灰度），像素值范围通常为 $[0, 255]$ 。
2. **卷积层**：利用多个卷积核（滤波器）提取局部特征，关键参数包括核大小、步长和填充；后接非线性激活函数（如 ReLU）引入非线性。
3. **池化层**：对特征图进行下采样（最大池化或平均池化），降低空间维度，减少计算量并抑制过拟合，同时保留主要特征。
4. **全连接层**：将提取的高层特征组合映射到分类或回归输出，常以 Softmax 输出各类别概率。

典型的前馈流程为：输入 $\rightarrow$ 卷积 + 激活 $\rightarrow$ 池化 $\rightarrow$ （可多次重复） $\rightarrow$ 展平 $\rightarrow$ 全连接 $\rightarrow$ 输出。

9.3 RNN

循环神经网络（RNN）是一类专门处理序列数据的神经网络。RNN 通过隐藏状态的循环连接，使得网络能够“记忆”历史信息，建模时间或序列上的依赖关系。

结构组成

- **输入层**：接收序列的每个元素。
- **隐藏层**：每个时刻的隐藏状态 $\mathbf{h}_t$ 依赖于当前输入 $\mathbf{x}_t$ 和前一时刻隐藏状态 $\mathbf{h}_{t-1}$ ，实现时序记忆。
- **输出层**：可输出序列的每一步结果或最终的汇总结果。

数学公式

基本递推关系为：

$$\mathbf{h}_t = \sigma_h(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h)$$

$$\mathbf{y}_t = \sigma_y(\mathbf{W}_{hy}\mathbf{h}_t + \mathbf{b}_y)$$

其中 σ_h 、 σ_y 为激活函数， $\mathbf{W}_{xh}$ 、 $\mathbf{W}_{hh}$ 、 $\mathbf{W}_{hy}$ 为权重矩阵。

典型应用

机器翻译、文本生成、语音识别、时间序列预测、情感分析等。

10 Transformer

Transformer 是一种完全基于自注意力机制的深度学习架构，它摒弃了传统的循环或卷积结构，通过并行计算输入序列中所有位置之间的全局依赖关系来建模数据；其核心组件包括多头自注意力、位置编码、前馈网络以及残差连接与层归一化，并采用编码器-解码器框架（亦可单独使用编码器或解码器）以处理序列到序列的任务。

10.1 自注意力机制

自注意力机制（Self-Attention），也称为内部注意力机制，是一种将单个序列的不同位置关联起来以计算同一序列的表示的注意力机制。这种机制允许模型在处理序列数据时，动态地调整对每个元素的关注程度，从而捕捉序列内部的复杂依赖关系。

Q、K、V 三个角色

每个输入词向量 $\mathbf{x}$ 通过三个线性变换分别生成：

- **Query（查询）**： $\mathbf{Q} = \mathbf{x}\mathbf{W}_Q$ ，表示“我要查什么？”
- **Key（键）**： $\mathbf{K} = \mathbf{x}\mathbf{W}_K$ ，表示“我能匹配什么？”
- **Value（值）**： $\mathbf{V} = \mathbf{x}\mathbf{W}_V$ ，表示“我提供什么信息？”

搜索引擎类比：Query = 搜索关键词；Key = 网页标题；Value = 网页内容。注意力权重 = Query 与各个 Key 的相似度，最终输出 = 用权重对 Value 加权求和。

注意力计算

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}$$

其中 d_k 是 Key 向量的维度，缩放因子 $\sqrt{d_k}$ 防止点积过大导致梯度消失/爆炸。Softmax 将相似度得分转化为概率分布（所有权重之和为 1）。

多头注意力

单一注意力空间捕捉模式有限，多头注意力将输入投影到 h 个不同子空间，每个“头”独立计算注意力，最后拼接结果，使模型能同时关注不同位置、不同语义层面的信息。

10.2 多头注意力机制

多头注意力机制是将自注意力机制并行执行多次，让每个头学习不同的注意力模式，最后拼接结果。

10.3 BERT and GPT Models

表 1: BERT 与 GPT 特性对比

特性	BERT	GPT
架构基础	Transformer 编码器	Transformer 解码器
注意力方向	双向	单向（因果）
预训练任务	掩码语言模型（完形填空）	自回归语言模型（续写）
核心能力	自然语言理解	自然语言生成
下游适配	微调（需要任务数据更新参数）	提示/上下文学习（无需/少需更新参数）
代表模型	BERT, RoBERTa, ALBERT	GPT-3, ChatGPT, GPT-4

10.4 Vision Transformer(ViT)

Vision Transformer (ViT) 是将 Transformer 架构引入计算机视觉的模型，通过将图像分块并作为序列输入 Transformer 编码器，实现无需卷积即可进行高效图像分类。

主要流程

- 图像分块 (Patch):** 将输入图像（如 $224 \times 224 \times 3$ ）均匀切割为固定大小的小块（如 16×16 ），得到 N 个图像块序列。
- 线性嵌入:** 将每个图像块展平为一维向量，并通过可训练的线性投影映射到固定维度，形成与 NLP 词向量相似的“块嵌入”。
- 位置编码:** 为每个块添加可学习的位置嵌入，以保留空间位置信息，使 Transformer 能够建模图像结构。
- Transformer 编码器:** 将带位置信息的序列输入标准 Transformer 编码器（仅 Encoder 部分），通过多头自注意力机制提取全局特征。
- 分类 Token:** 在序列开头添加一个特殊的可学习分类 token，其对应的编码器输出向量经过 MLP 头用于最终的类别预测。

应用与优势

- **图像分类**：在大规模数据集预训练后，ViT 的分类精度可超越传统 CNN 模型。
- **迁移学习**：预训练 ViT 能高效迁移到下游视觉任务，展现出出色的泛化能力。
- **架构灵活性**：ViT 思想可自然扩展至目标检测、图像分割等任务，并可结合掩码自编码器（MAE）、自监督方法（如 iBOT）进一步提升性能。

11 生成模型

在机器学习中，生成模型可以用来直接对数据建模，也可以用来建立变量间的条件概率分布。条件概率分布可以由生成模型根据贝叶斯定理形成。

11.1 GAN

生成对抗网络（Generative Adversarial Network, GAN）是深度学习中最具创意的模型架构之一。它通过让两个神经网络相互对抗、相互学习，最终能够生成非常逼真的数据。GAN 广泛应用于图像生成、风格迁移、数据增强等场景。

GAN 核心原理概括

生成对抗网络（GAN）的设计源于博弈论中的零和博弈，包含两个相互对抗的神经网络：

- **生成器**：学习生成与真实数据相似的假样本，目标是使判别器无法正确分辨；
- **判别器**：学习区分真实样本与生成样本，目标是尽可能准确地识别。

两者在交替训练中持续对抗优化，最终达到纳什均衡。

目标函数

GAN 的训练可形式化为如下的极小极大优化问题：

$$\min_G \max_D \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

其中 G 为生成器， D 为判别器， $\mathbf{x}$ 为真实数据， $\mathbf{z}$ 为随机噪声（通常服从标准正态分布）， $G(\mathbf{z})$ 为生成的假数据。

训练过程

训练分两阶段交替进行：

1. **训练判别器**：固定生成器，最大化判别器对真实数据与生成数据的分类能力：

$$\max_D \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z} [\log(1 - D(G(\mathbf{z})))]$$

2. **训练生成器**：固定判别器，最小化生成器被识别的概率，即提升欺骗能力：

$$\min_G \mathbb{E}_{\mathbf{z} \sim p_z} [\log(1 - D(G(\mathbf{z})))]$$

11.2 VAE

变分自编码器（Variational Autoencoder, VAE）是一种生成模型，它将数据编码为潜在空间中的概率分布，而非固定向量。这使得我们可以从潜在空间中采样生成新数据。

核心原理概括

变分自编码器（VAE）的关键创新在于对潜在变量概率分布的学习。编码器不直接给出潜在向量，而是输出潜在空间的均值 μ 与标准差 σ ，并借助重参数化技巧从正态分布 $\mathcal{N}(\mu, \sigma^2)$ 中采样得到潜在向量 $\mathbf{z}$ ，即

$$\mathbf{z} = \mu + \sigma \cdot \epsilon, \quad \epsilon \sim \mathcal{N}(0, 1),$$

从而保证了整个采样过程的可微性。解码器则基于该潜在向量 $\mathbf{z}$ 重构原始数据。

11.3 Diffusion

扩散模型（Diffusion Models）是一类强大的生成模型，它通过学习数据的逐步去噪过程来生成高质量的样本。这个过程可以类比为物理学中的扩散现象：就像墨水在水中逐渐扩散直至均匀分布，扩散模型将数据逐步添加噪声直至变成纯噪声，然后学习如何反转这个过程。

前向扩散过程（加噪）

前向扩散是一个逐步向图像添加高斯噪声的过程，直至图像变为纯噪声。这一过程是确定的，通过预定义的噪声调度，可以直接计算任意时刻 t 的噪声状态 $\mathbf{x}_t$ ：

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I})$$

其中 β_t 为噪声强度参数。

反向去噪过程

反向过程是前向过程的逆：从纯噪声 $\mathbf{x}_T$ 开始，模型在每一步预测并去除噪声，逐步恢复原始图像。模型需要学习的是：给定当前噪声图像 $\mathbf{x}_t$ 与时间步 t ，预测所添加的

噪声 $\epsilon_{\theta}(\mathbf{x}_t, t)$ 。

训练目标

训练时最小化模型预测噪声与真实添加噪声之间的均方误差：

$$\mathcal{L} = \mathbb{E}_{\mathbf{x}_0, \epsilon, t} \left[\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2 \right]$$

其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 为实际加入的噪声。

U-Net 架构

扩散模型的核心是一个 U-Net 网络，结构呈“U”形：左侧下采样逐层压缩图像，右侧上采样逐层恢复分辨率。其关键设计是**跳跃连接**：将下采样路径上的特征图直接传递给上采样路径的对应层，从而有效保留细粒度的细节信息，避免信息丢失。

Stable Diffusion 架构

Stable Diffusion 在隐空间而非像素空间中执行扩散过程，显著提升了效率。完整架构包含三个模块：

1. **VAE**（变分自编码器）：将图像压缩为低维隐向量，或从隐向量还原图像。
2. **UNet**：核心去噪网络，接收隐向量、时间步以及提示词的嵌入，预测应去除的噪声。
3. **Text Encoder**（基于 CLIP）：将文本提示转换为高维嵌入，为生成过程提供语义指导。

总结

本文从理论和数学层面出发，首先介绍了机器学习的基本框架、深度学习中前向传播与反向传播的机理、训练收敛和基础性能指标。随后逐个解析了机器学习和深度学习中经典模型的核心原理和基本架构。这些内容构成了机器学习和深度学习入门的理论基石，为我们后续学习更复杂的模型和理论提供了坚实的基础。

参考文献

- [1] 何清, 李宁, 罗文娟, 等. 大数据下的机器学习算法综述 [J]. 模式识别与人工智能, 2014, 27(4): 327-336.

- [2] Mathew A, Amudha P, Sivakumari S. Deep learning techniques: an overview[C]//International conference on advanced machine learning technologies and applications. Singapore: Springer Singapore, 2020: 599-608.
- [3] Alpaydin E. Machine learning[M]. MIT press, 2021.
- [4] Pandey D, Niwaria K, Chourasia B. Machine learning algorithms: a review[J]. Mach. Learn, 2019, 6(2): 916-922.